中山大学计算机学院

人工智能实验报告

课程名称：Artificial Intelligence

教学班级	超算班	专业	信息与计算科学
学号	21307261	姓名	王健阳

一，实验题目

文本处理与KNN

二，实验内容

算法原理

先对训练集进行处理，提取出训练集每个句子的特征并统一化为$one-hot$矩阵。对于测试集的每一个句子，先把其处理为与训练集一样表示的$one-hot$向量，再计算两者之间的距离（此处可采用多种距离定义），对于测试集的一个句子对应的N个距离，取前k个作为我们的参考集合，取其中情绪的众数作为预测值。

伪代码

```
# 读取文件
train_data, test_data = readfile()
# 将数据集统一为one-hot向量矩阵
matrix = data_processing(train_data)
cnt = 0
# 遍历测试集每一个句子
for sentence in test_data:
    # 转化为one-hot向量
    vec = convert(sentence)
    distance_list = []
    for row in matrix:
        dis = GetDis(row, vec)
        distance_list.append(dis)
    # 排序并取前k个作为参考集合
    distance_list.sort()
    container = distance_list[:k]
    # 如果参考集合里面的众数等于实际情感，则预测成功
    if sentence.emotion == GetMode(container):
        cnt += 1
```

关键代码展示

```python
import numpy as np
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
import math


p = -1


# 计算两向量之间的距离
def GetDistance(vec1, vec2):
    global p
    distance = 0.0
    dist_vec = vec1 - vec2
    # p-范数
    if p > 0:
        for i in range(len(dist_vec)):
            distance += math.fabs(dist_vec[i]) ** p
        distance = distance ** (1 / p)
    # 无穷范数
    elif p < 0:
        for i in range(len(dist_vec)):
            distance = math.fabs(dist_vec[i]) if math.fabs(dist_vec[i]) > distance
else distance
    # 余弦表示法，模采取2-范数
    else:
        numerator = 0
        len1, len2 = 0, 0
        for i in range(len(vec1)):
            numerator += vec1[i] * vec2[i]
            len1 += vec1[i] ** 2
            len2 += vec2[i] ** 2
        distance = - (numerator / math.sqrt(len1 * len2))
        # print(distance)
    return distance


# 数据初始化
def DataInit():
    file_test = open('Classification/test.txt', 'r').read().split('\n')[1:-1]
    data = []
    for item in file_test:
        temp = item.split(' ')
        data.append([temp[2], ' '.join(temp[3:])])
    return data


class KNN:
    accuracy = 0.0

    def __init__(self, data):
        # 将训练集测试集句子放在一起提取特征，避免出现测试集单词训练集中不存在的情况
        # 此举便于向量匹配
        self.N = round((len(data)) * 0.8)
```

```
        self.k = round(math.sqrt(self.N)) + 4

        self.data = data
        cv = CountVectorizer()
        cv_fit = cv.fit_transform(np.array(self.data)[:, 1])
        self.train_emotion = np.array(self.data[:self.N])[:, 0]
        self.test_emotion = np.array(self.data[self.N:])[:, 0]
        self.name_list = cv.get_feature_names_out()
        self.matrix = cv_fit.toarray()

        print('N = ', self.N, '  ', 'k = ', self.k)
        print('p = ', p)

    def Solution(self):
        denominator, numerator = len(self.data) - self.N, 0
        cnt = 0
        for i in range(denominator):
            # emotion_predict = self.Predict(i)
            # 对于测试集里的每一个句子，进行情感预测
            emotion_predict = self.Predict(i)
            if emotion_predict == self.test_emotion[i]:
                numerator += 1
            cnt += 1
            print(emotion_predict, end=' ' if cnt % 20 != 0 else '\n')
        self.accuracy = round(numerator / denominator, 5)
        print('\n', self.accuracy)

    def Predict(self, sentence_index):
        emo_dict = {'anger': 0, 'disgust': 0, 'fear': 0, 'surprise': 0, 'sad': 0,
'joy': 0}
        # 获得待预测句子的one-hot向量
        vec = self.matrix[sentence_index + self.N]
        container = []
        for index, train_vec in enumerate(self.matrix[:self.N]):
            temp = [index, GetDistance(vec, train_vec), self.train_emotion[index]]
            container.append(temp)
        # 进行排序并保留前k个样本
        container.sort(key=lambda x: x[1])
        # print(container[:self.k])
        for item in container[:self.k]:
            emo_dict[item[2]] += 1
        return list(emo_dict.keys())
[list(emo_dict.values()).index(max(list(emo_dict.values())))]


if __name__ == '__main__':
    Data = DataInit()
    solution = KNN(Data)
    solution.Solution()
```

创新点 & 优化

将训练集与测试集一起提取特征，避免了进行向量匹配时不匹配项的出现。哪怕测试集中存在训练集中没有的单词，也可以直接进行运算。

三，实验结果及分析

在给定的文本数据集（Classification.zip）完成文本情感分类训练，在测试集完成测试，计算准确率。需要对上次给的数据集（Classification.zip）进行重新划分，训练集：测试集为8：2。故以下的输出是基于`test.txt`句子按照$训练：测试 = 8：2$来运行的

算法结果展示实例

超参k对准确率的影响

以下为p固定取2的时候，对超参k取值的分析

k初始值设为28，约为$N^\frac{1}{2}$

```
N =  800    k =  28
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad fear joy joy joy joy

 0.35
```

> k逐渐增大

```
N =  800    k =  29
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy fear joy joy joy joy joy joy joy joy joy joy joy joy sad fear joy joy joy joy

 0.355
```

```
N =  800    k =  30
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy fear joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy joy joy

 0.35
```

```
N =  800    k =  32
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy sad joy joy joy joy joy joy joy joy fear joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy

 0.36
```

```
N =  800    k =  33
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy

 0.35
```

> k逐渐减小

```
N =  800    k =  27
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad fear joy joy joy joy

 0.35
```

经过考察发现，k取32的时候有局部最优解。

距离度量考察

以下探究在k取32的前提下，改变距离度量方式对正确率的影响

> p = 1

```
N =  800    k =  32
p =  1
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy sad joy joy joy joy joy joy joy joy fear joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy

 0.36
```

> p = 3

```
N =  800    k =  32
p =  3
joy joy joy joy joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy sad joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy sad joy joy joy joy joy joy joy joy fear joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy sad joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy
joy fear joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy joy

 0.36
```

> p = $+\infty$

```
N =  800    k =  32
p =  -1
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise joy surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise
surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise surprise

 0.235
```

> 余弦相似度

```
N =  800    k =  32
p =  0
surprise joy sad joy joy sad fear surprise surprise sad joy joy surprise surprise joy surprise sad surprise joy joy
joy joy surprise surprise sad joy joy fear fear surprise sad joy joy joy surprise joy joy joy sad surprise
joy sad surprise joy joy joy sad joy joy joy joy surprise surprise joy surprise surprise surprise surprise fear joy
joy joy sad sad joy joy sad anger fear joy joy joy fear sad sad joy fear joy sad surprise
joy joy surprise joy joy surprise fear joy sad joy joy surprise joy surprise surprise joy sad joy fear surprise
surprise surprise fear sad joy surprise joy joy joy surprise joy joy joy surprise surprise surprise surprise joy joy joy
joy sad surprise joy joy joy joy sad surprise joy surprise fear joy joy joy surprise sad joy surprise joy
fear joy joy surprise joy joy joy joy sad sad fear fear joy sad joy sad sad joy joy sad
joy surprise joy surprise joy joy surprise joy sad joy sad joy joy surprise joy joy surprise joy joy joy
surprise sad joy joy fear surprise sad sad surprise joy joy sad sad joy sad joy joy sad joy surprise

 0.4
```

可以看出，在选择余弦相似度作为测量依据的时候，测量准确率相对最高。

评测指标展示及分析

不难看出，k在取到32的时候会有最大值0.36。故根据此次训练集训练出来的模型，在选择余弦相似度作为测量依据，k取32的时候，测试集得到的准确率最高。最后优化之后的正确率保持在0.4左右。

四，思考题

此次实验没有思考题

五，参考资料

1.实验python基础pdf

2.CSDN